

Glosario para la defensa oral

Los 13 términos del glosario de la rúbrica (págs 11-12) + 1 bonus. Cada uno tiene 3 secciones: definición técnica, cómo explicarlo al gerente, y ejemplo aplicado al proyecto. **Práctica:** poder decir los 3 niveles SIN LEER. Si no podés, usar */grill-me* o */gentleman* para repasar.

Sobre el problema

Churn

- **Técnico:** evento en que un cliente deja de comprarnos / cancela el servicio.
- **Para el gerente:** "Como un alumno que se borra del gimnasio sin avisar — pagaba todos los meses, ahora no más."
- **En el proyecto:** target binario *Churn* (1 = se fue, 0 = sigue activo). 16.8% de la base churneó el año pasado = 945 clientes de 5,630.

Class imbalance (desbalance de clases)

- **Técnico:** una clase del target aparece sustancialmente menos que la otra. En clasificación, típicamente la clase positiva (lo que queremos detectar) es la minoría.
- **Para el gerente:** "Si decís que todos son diestros, acertás 90% de las veces — pero no aprendiste a distinguir nada. Lo mismo si predecís 'nadie churna': te da 83% de acierto sin servir para nada."
- **En el proyecto:** 83% no-churn / 17% churn. Tratamiento: *class_weight='balanced'* en RF/DT, *scale_pos_weight* en XGBoost, y Recall como métrica primaria en lugar de Accuracy.

Leakage (fuga de información)

- **Técnico:** cuando el modelo se entrena con información que en la realidad no estaría disponible al momento de hacer la predicción.
- **Para el gerente:** "Estudiar con las respuestas del examen al lado. Funciona perfecto en el lab — falla apenas el modelo va a producción y no tiene esa información."
- **En el proyecto:** dos casos:
 - **Riesgo no validable** con *Complain* (no sabemos si la queja se registra antes o después del churn). Postura conservadora: la dropeamos.
 - **Prevención sistemática** en el pipeline: split ANTES de imputar, todas las estadísticas (medianas, percentiles, encoders) se fitean SOLO con train.

Sobre el experimento

Train/test split

- **Técnico:** dividir el dataset en dos subconjuntos. Train (típicamente 80%) para entrenar el modelo. Test (típicamente 20%) para evaluarlo en datos que nunca vio.
- **Para el gerente:** "El examen sorprende que el modelo no puede ver hasta el final. Si entrenas y evaluas con los mismos datos, parece que sabe todo — pero falla apenas le mostrás un caso nuevo."
- **En el proyecto:** `test_size=0.2, stratify=y, random_state=42`. Train: 4504 clientes. Test: 1126 clientes.

Stratified (estratificado)

- **Técnico:** el split respeta la proporción de cada clase del target en ambos subconjuntos.
- **Para el gerente:** "Que ambas porciones de la torta tengan el mismo porcentaje de chocolate. Si el dataset tiene 17% de churn, tanto train como test van a tener cerca del 17%."
- **En el proyecto:** sin stratify, por azar podríamos terminar con 19% churn en train y 11% en test. El modelo aprendería un mundo y se evaluaría en otro. Estratificar garantiza distribución idéntica: train 16.83% / test 16.87%.

Sobre los modelos

Baseline / Dummy

- **Técnico:** el modelo más simple posible. Predice siempre la clase mayoritaria o aleatoria. Sirve como **piso de comparación** — si un modelo complejo no le gana al dummy, algo está mal.
- **Para el gerente:** "Si el modelo complejo no le gana a tirar una moneda al aire para cada cliente, algo salió muy mal. Sirve para validar que el modelo está aprendiendo algo real."
- **En el proyecto:** `DummyClassifier(strategy='most_frequent')` predice siempre "no churn" → 83% accuracy, **0% Recall**. Confirma que accuracy engaña en datasets desbalanceados.

Decision Tree (árbol de decisión)

- **Técnico:** modelo que hace preguntas sí/no en cascada hasta clasificar. Cada split divide los datos por una variable.
- **Para el gerente:** "Un cuestionario: ¿Tenure menor a 6 meses? → sí → ¿hizo Complain? → sí → riesgo alto. Fácil de leer y explicar."
- **En el proyecto:** obligatorio per rúbrica. Recall CV 0.7652 — 8 puntos por debajo de RF. Sirve para interpretabilidad pero no es el modelo final.

Random Forest

- **Técnico:** ensemble de muchos árboles de decisión, cada uno entrenado en una muestra bootstrap de los datos. Predicción = voto mayoritario (clasificación) o promedio (regresión).
 - **Para el gerente:** "En vez de preguntarle a un médico, le preguntás a 500 distintos y votan. Más robusto, mejor que cualquiera por separado."
 - **En el proyecto:** ganador. RF V1 tuneado: `n_estimators=1469`, `max_depth=50`, `min_samples_leaf=3`, `max_features=0.978`. Recall CV 0.8629, Recall test 0.9526.
-

Sobre las métricas

Accuracy

- **Técnico:** porcentaje total de aciertos sobre el total de casos.
 - **Para el gerente:** "Suena buenísimo en datasets balanceados, miente en los desbalanceados. Decir 'nadie churna' da 83% de aciertos pero detecta cero churners. Es inútil para esto."
 - **En el proyecto:** la reporto solo como informativo (0.98 en test). **NUNCA** como métrica principal.
-

Recall (sensibilidad / true positive rate)

- **Técnico:** de todos los casos positivos reales, ¿qué fracción detectó el modelo? $TP / (TP + FN)$.
 - **Para el gerente:** "El radar del hospital: de cada 10 personas que iban a churnear, ¿a cuántas detectamos? Mejor radar = menos pérdidas."
 - **En el proyecto:** métrica PRIMARIA. Recall en test = 95.3% → detectó 181 de 190 churners reales. La consigna justifica priorizar Recall por costo asimétrico.
-

Precision (positive predictive value)

- **Técnico:** de todas las predicciones positivas del modelo, ¿qué fracción son verdaderos positivos? $TP / (TP + FP)$.
 - **Para el gerente:** "De cada 10 personas que mandamos a tratamiento, ¿cuántas lo necesitaban realmente? Si es 8 de 10, estamos bien."
 - **En el proyecto:** Precision en test = 81.2%. De 223 alertas del modelo, 181 son churners reales (42 falsas alarmas). Trade-off deliberado para subir Recall.
-

F1 score

- **Técnico:** media armónica de Precision y Recall. Penaliza más los desbalances que la media simple.
- **Para el gerente:** "Una nota que combina las dos anteriores. Si una de las dos está mal, F1 baja. Sirve

para tener una sola nota."

- **En el proyecto:** F1 test = 0.876. Lo reporto pero la métrica primaria sigue siendo Recall.

SHAP values

- **Técnico:** valores de Shapley aplicados a explicabilidad de modelos. Para cada predicción, descompone la contribución de cada feature al resultado final (suma de SHAP values + valor base = predicción).
- **Para el gerente:** "El ticket del supermercado: no solo el total final, sino qué producto contribuyó cuánto al total. Para cada cliente, podemos ver qué factores empujaron la predicción de riesgo."
- **En el proyecto:** uso SHAP globalmente (qué features pesan más en general — slide 12) y localmente (por qué para ESTE cliente específico la predicción fue X — Apéndice).

Bonus

BayesSearchCV (Bayesian optimization)

- **Técnico:** algoritmo de búsqueda de hiperparámetros que usa un modelo gaussiano sobre las evaluaciones previas para decidir qué configuración probar a continuación. Más eficiente que GridSearchCV y RandomizedSearchCV en espacios continuos.
- **Para el gerente:** "En vez de probar todas las combinaciones (que tarda años) o tirar dardos al azar, aprende de las pruebas anteriores. 'Si probaste 100 cosas y la mejor fue esta zona, vamos a buscar más cerca de ahí.'"
- **En el proyecto:** lo usé para tunear RF y XGBoost. Hice 3 rondas: 30 iters, 100 iters expandidos, 50 iters narrow. La iteración fue clave para descubrir que los best_params estaban pegados a los boundaries del search space original.

Cómo practicar este glosario

1. **Decirlos en voz alta** — los tres niveles (técnico, gerente, proyecto) de cada uno.
2. **Sin leer** — si necesitas leer, todavía no lo tenés.
3. **En orden aleatorio** — el evaluador no va a preguntarte en el orden de esta lista.
4. **Con presión** — usar `/grill-me` que va a interrogarte con preguntas seguidas.

Tiempo objetivo: 30 segundos por término. Si tardás más, la respuesta es muy técnica para una defensa oral.

Donde defender cada decisión

Si el evaluador pregunta por una decisión específica, todas están documentadas en `decisions.md`:

Tema	Decisión en <code>decisions.md</code>	Slide(s)
------	---------------------------------------	----------

Por qué Recall	#1 — Elección de métrica	10
Por qué dropear Complain	#19 — Drop definitivo Complain	7
Por qué stratified split	#5 — Split estratificado	3
Por qué imputación con mediana	#7 — Imputación con mediana	7
Por qué OHE y no OrdinalEncoder	#9 — One-Hot Encoding	7
Por qué RF como familia	#17 — RF como familia ganadora	8
Por qué RF V1 tuneado	#18 — Adopción RF V1 tras iteración	9
Por qué descartar tuneado al principio	(en #18, narrativa)	9

Si te preguntan algo que no recordás de memoria, podés decir: *"Esa decisión está documentada en [decisions.md](#) con su contexto completo — ¿querés que la abra?"*. Eso muestra que sabés dónde está la información y no estás improvisando.