

TP Churn de Clientes

Inteligencia Artificial Aplicada a Negocios

Licenciatura en Negocios y Tecnología · Primer Cuatrimestre 2026

Tu rol en este TP

No sos el programador. Sos el responsable de negocio que entiende el problema, dirige la solución con IA, interpreta los resultados y defiende cada decisión frente al gerente comercial.

1. Objetivo del TP

Imagina que sos analista de retención en una empresa de e-commerce con 5.630 clientes activos. El año pasado se fue cerca del 17% de la base. El gerente comercial te pregunta:

*"¿Podemos detectar qué clientes están por irse, antes de que dejen de comprar?
¿Por qué nos dejan?"*

Para responderle, vas a trabajar con un dataset real, usar IA como copiloto técnico y construir un modelo predictivo. Pero el foco de tu carrera no está en el modelo: está en lo que hacés con él.

Lo que buscamos en Negocios y Tecnología

No buscamos el modelo más preciso. Buscamos que entiendas qué resuelve, por qué funciona, qué limitaciones tiene, y cómo se lo explicás a alguien que toma decisiones.

2. Qué tenés que entregar

Cuatro entregas en cuatro semanas. Cada una construye sobre la anterior.

Entregable	Qué es	Para qué sirve	Fecha de entrega
* EDA	Exploración de datos con hipótesis de negocio y gráficos	Entender quiénes son los clientes y qué patrones predicen churn	12/06
Código + Github + skills	el código base debe estar definido, en un repo github, y los skills instalados	para tener el código base que se utilizará para luego modelar	12/06
Notebook Modelado	Modelo baseline + modelo potente con métricas correctas	Demostrar que la herramienta funciona y que elegiste la métrica correcta	19/06
decisions.md	Registro de cada decisión importante: qué, por qué, qué alternativas descartaste	Memoria del proyecto. La usás en la defensa oral.	12/06 y 19/06
Reporte ejecutivo + defensa oral	PDF de 4-6 páginas para el gerente comercial + presentación oral de 15 minutos	Comunicar resultados sin tecnicismos y defender decisiones	19/06

* EDA = Exploratory Data Analysis (Análisis Exploratorio de Datos).

Es la fase donde **entendés el dataset antes de modelar**. No construís nada predictivo todavía, primero mirás qué hay, cómo se distribuye, qué relaciones existen.

Qué hacés en un EDA típico:

- **Estadísticas básicas** → promedios, medianas, valores mínimos/máximos, nulos
- **Distribuciones** → histogramas, boxplots para ver si los datos están sesgados
- **Correlaciones** → qué variables se mueven juntas
- **Segmentaciones** → clientes que se fueron vs. los que no, ¿en qué se diferencian?
- **Detección de anomalías** → outliers, datos raros, columnas con 90% de nulos

En el contexto del proyecto de churn:

El notebook EDA es donde responde preguntas como:

- ¿Qué edad promedio tienen los clientes que se van?
- ¿Los que tienen más productos se van menos?
- ¿Hay algún indicio que indique que el churn es mucho mayor?

Todo eso con gráficos y tablas, sin todavía construir un modelo ni código

2.1 Evaluación

Las dimensiones no pesan igual para Negocios y Tecnología. La comunicación y el entendimiento valen más que la ejecución técnica.

Dimensión	Qué se evalúa
Entendimiento del problema y los datos	¿Sabés qué pregunta estás respondiendo y con qué datos?
Análisis exploratorio e hipótesis de negocio	¿Tus hipótesis tienen lógica de negocio? ¿Las validaste?
Modelado, métricas y elección justificada	¿Elegiste bien la métrica? ¿Sabés por qué ese modelo?
Comunicación ejecutiva y defensa oral	¿Podés explicárselo a un gerente? ¿Defendés cada decisión?

3. Mentalidad antes de arrancar

La IA es tu copiloto técnico, no tu reemplazante

Tu trabajo no es escribir código. Es entender el problema, formular las preguntas correctas, delegar la ejecución a la IA, y validar que lo que te devuelve tiene sentido de negocio. Si no podés explicar por qué la IA hizo lo que hizo, no estás listo para la defensa.

Antes de aceptar cualquier output de la IA, hacete estas tres preguntas:

- ¿Esto tiene sentido para el problema que estamos resolviendo?
- ¿Podría explicarle esto al gerente comercial sin tecnicismos?
- ¿Por qué esta opción y no otra?

Si no podés responderlas, usá la skill grill-me: te interroga hasta que entiendas de verdad. Es incómoda. Por eso funciona.

4. Cómo lo vas a hacer: el flujo de trabajo

Tu flujo de trabajo como responsable de negocio tiene tres movimientos, que se repiten en cada tarea:

Paso	Nombre	Qué hacés
1	Entender	Antes de pedirle algo a la IA, asegurate de entender qué pregunta de negocio estás respondiendo. Usá grill-me si tenés dudas sobre el concepto.
2	Delegar	Le explicás el contexto a la IA, le pedís que proponga 2-3 alternativas antes de ejecutar, y elegís la que tenga más sentido para tu problema.
3	Validar	Revisás el output. No si el código corre — si el resultado tiene sentido. Documentás la decisión en decisions.md con el razonamiento.

5. Herramientas

Usás las herramientas de Ciencia de Datos, con un foco diferente: vos operás desde el rol de quien entiende y decide, no de quien implementa.

Cursor

Tu editor de código con IA integrada. No necesitás dominar Python , necesitás saber pedirle bien las cosas y entender lo que te devuelve.

grill-me

Skill que te interroga sobre cualquier concepto hasta que lo entendés de verdad. Usala cada vez que veas un término del glosario que no te queda claro.

<https://skills.sh/mattpocock/skills/grill-me>

Skill Gentleman

Tu profesor privado. Te explica cualquier concepto con voz criolla y analogías. Si el glosario no alcanza, invocalo.

decisions.md

Un archivo de texto donde registrás cada decisión importante del proyecto. Formato sugerido para cada entrada:

```
## Decisión — [título breve]
```

1. Qué decidí: ...
2. Por qué: ...
3. Alternativas que descarté: ...
4. Consecuencias: ...

Este archivo es tu memoria. En la defensa oral podés consultarlo. Si una decisión te costó más de 5 minutos pensar, va acá.

6. Cronograma

Semana 1 : Setup y entendimiento del problema

Antes de tocar los datos, entendé el negocio. Respondé por escrito:

- ¿Qué es churn y por qué le importa económicamente a la empresa?
- ¿Qué significa que adquirir un cliente nuevo cuesta 5-7 veces más que retener uno?
- ¿Qué decisión concreta va a tomar el gerente comercial con tu análisis?

Configurá tu entorno: Cursor, GitHub, entorno Python, skills.

Instalaciones de setup

- Descargate Cursor y créate una cuenta nueva:
<https://cursor.com/es/download>.
Crea un entorno python: https://youtu.be/9wlupY_Lo_w?si=6vUub1_PAvqmydgi
- Create una cuenta en github: https://youtu.be/a9u2yZvsqHA?si=75Yhz4a_9nrw4WPn

Conectala con Cursor: https://youtu.be/SFaX8sHgQmQ?si=_y74iBT8tHFfdXTX
- **Video explicativo de gente-ai:** https://youtu.be/UoS_LP-PCG8?si=-0mZ9whHh7VoKt7G
- **Instalador:** <https://github.com/Gentleman-Programming/gentle-ai>. Te va a instalar Engram (base de datos muy chica para guardar tus decisiones y tener memoria persistente), gentleman voice (forma de hablar argentina de un tutor senior para que te explique las cosas que no entendes) y sdd-flow para orquestar los subagentes (útiles para desarrollar cualquier feature)
- **Skills:** instalá mis skills de data science
<https://github.com/agus-chaud/data-science-kit/tree/main> y la de grill-me
<https://skills.sh/mattpocock/skills/grill-me>

Checkpoint antes de seguir

Si no podés cargar el CSV en un notebook y mostrar `df.head()` , no pases a la sección 3.

Si el entorno virtual no está activo, no pases a la sección 3.

Si el primer commit no está hecho, no pases a la sección 3.

¿Por qué tanta exigencia? Porque empezar con un setup roto es empezar perdiendo 2 horas por día durante 3 semanas.

4.1 Dataset E-commerce Customer Churn

El dataset que les damos tiene

- 5.630 filas, 20 columnas (1 ID + 1 target + 18 features)
- **Target:** columna Churn (1 = se fue, 0 = sigue activo)
- **Class imbalance:** ~17% Churn=1, ~83% Churn=0 → ojo con la accuracy como métrica
- **Valores nulos:** 7 columnas tienen NaN (Tenure, WarehouseToHome, HourSpendOnApp, OrderAmountHikeFromlastYear, CouponUsed, OrderCount, DaySinceLastOrder). Vas a tener que decidir cómo manejarlos.
- La hoja "Data Dict" tiene la descripción de cada variable. Leela antes de modelar.
- Guardá una copia en `data/raw/` y NUNCA la edites ahí

4.2 Variables principales

- **Tenure** — meses como cliente. Sospechá fuerte que es predictora.
- **SatisfactionScore** — score 1-5. ¿Predice churn? Hipótesis obvia, validala.
- **Complain** — ¿reclamó el último año? Cuidado con leakage temporal.
- **DaySinceLastOrder** — días desde su última orden. Otra sospechosa.
- **CashbackAmount, OrderCount, CouponUsed** — comportamiento transaccional.
- **CityTier, Gender, MaritalStatus** — demográficas, sirven para análisis de subgrupos.

Esta semana la pasás entendiendo los datos y formulando hipótesis con lógica de negocio. Un alumno de Datos explora variables. Vos formulás preguntas que importan, ejemplos:

- H1: Los clientes nuevos (Tenure bajo) tienen mayor riesgo de irse. ¿Por qué tendría sentido esto?
- H2: Los clientes que se quejaron (Complain = 1) churnean más. ¿Es esta variable confiable temporalmente?
- H3: Los clientes con muchos días sin comprar están más cerca de irse.

Para cada hipótesis: un gráfico que la muestre visualmente, una interpretación en lenguaje de negocio.

Semana 2 : Exploración e hipótesis de negocio

Habiendote instalado el data science kit , usá al subagente planificador ds-planner y pasale la consigna entera. Tenes que transformar los entregables en parte en fases chicas y verificables, para ir desarrollando de a poco y entendiendo. Una vez que crees el plan, pedile que te proponga 4 mejoras concretas y pensá si tienen sentido. La IA puede automejorarse cuando se lo exigis.

Análisis exploratorio de datos, asistido por subagente

Invocá al subagente ds-explorer y ejecuta sólo esa parte del plan que creaste. Pedile un perfilado completo, pero NO aceptes el output crudo. Leelo, cuestionalo.

Hipótesis de negocio (antes de modelar)

Escribí 5 hipótesis en reports/01_hipotesis.md. Por ejemplo:

- H1: Los jóvenes (Age < 30) churnean más
- H2: Quienes son CityTier 2 y tienen complain churnean más
-

Verificá cada hipótesis con un gráfico y un test estadístico. Esto es lo que te diferencia del que solo tira un RandomForest.

Split: Separá los datos antes de usarlos

Imaginate que sos profe: no le podés dar a tus alumnos el mismo examen que practicaron en clase, porque no estarías midiendo si entendieron. Con un modelo es igual: separás los datos en train (80%, lo que el modelo "estudia") y test (20%, el examen final con el que evaluas al modelo entrenado). Y lo hacés PRIMERO, antes de limpiar, escalar o rellenar nada , porque si retocás los datos antes de separarlos, estás espiando el examen sin querer.

Además, partilo estratificado: como sólo el 17% de los clientes churnea, si partís al azar podés terminar con 19% en train y 11% en test, y el modelo aprende un mundo y se evalúa en otro. Estratificar fuerza que ambas partes tengan el mismo 17% que el original.

- train_test_split con stratify=y, test_size=0.2, random_state fijo

Dividís el dataset en dos partes:

- **Train** → el modelo aprende con estos datos
- **Test** → evaluás qué tan bien predice en datos que nunca vio

Si entrenás y evaluás con los mismos datos, el modelo parece perfecto pero en producción falla. Es como estudiar con el examen ya resuelto.

2. Por qué estratificado

El problema con churn es que la clase positiva (los que se van) es minoría — en este caso 16% del dataset.

Si el split es **aleatorio puro**, por azar podés terminar con:

- Train: 18% churn
- Test: 10% churn

Ahora el modelo aprendió con una distribución y lo evaluás con otra. Los resultados no son comparables y **todo se contamina**.

Estratificado significa que el split respeta la proporción original en ambos subsets. Si el dataset tiene 16% de churn, tanto train como test van a tener ~16%. La distribución queda idéntica.

3. Los parámetros del código

```
python train_test_split(X, y, stratify=y, test_size=0.2, random_state=42)
```

- **stratify=y** → hace el split estratificado usando la variable target (**y** = churn sí/no)
- **test_size=0.2** → 20% va a test, 80% a train
- **random_state fijo** → congela el azar. Si ponés **random_state=42** hoy y lo volvéis a correr mañana, el split es idéntico. Eso hace el experimento **reproducible**, cualquier persona que lo ejecute en cualquier computadora va a tener exactamente los mismos resultados

Ojo con el leakage

Algunas variables pueden estar 'espiando' el futuro. La variable **Complain**, por ejemplo: ¿se registró antes o después de que el cliente se fuera? Si es después, usar esa variable es hacer trampa. Documentá si hay riesgo de leakage en cada variable sospechosa.

* **Data leakage** es cuando el modelo se entrena con información que en la realidad no estaría disponible al momento de hacer la predicción.

La variable **Complain** (el cliente se quejó). El problema es **cuándo se registró ese dato**:

- Si la queja ocurrió **antes** de que el cliente decidiera irse → es una señal legítima, el modelo puede usarla
- Si la queja se registró **después** de que el cliente ya se fue → el modelo está "viendo el futuro" durante el entrenamiento

Semana 3: Modelos predictivos

Modelo baseline

Antes de meterte con modelos complicados, arrancá con el más simple posible: tu "piso" de comparación. La idea es esta: si después un modelo más potente y elegante no le gana a este simple, algo está haciendo mal. Si entrenás un modelo bobo que diga "ningún cliente va a churnear, todos se quedan", va a acertar el 83% de las veces (porque sólo el 17% realmente se va). ¡83% suena buenísimo! Pero es inútil: de los clientes que sí se iban, detectó cero. Cero. Por eso la "accuracy" (porcentaje de aciertos) miente cuando el problema está desbalanceado: te hace sentir un genio mientras tu modelo no sirve para nada. Basate en cuántos clientes de los que se iban realmente pudiste detectar (Recall).

Modelos potentes

Árbol de decisión (obligatorio) : un modelo que va haciendo preguntas tipo "¿Tenure menor a 6 meses? → sí → ¿hizo Complain? → sí → riesgo alto". Súper fácil de leer y entender qué está haciendo. Empezá por acá.

Random Forest (opcional): en vez de un solo árbol, son cientos votando juntos. Mucho más robusto, suele ganarle al árbol de decisión. Decile que preste especial atención a los clientes que churnean (que son minoría).

Cómo medís si el modelo es bueno

En vez de evaluar una sola vez, repetí el experimento 5 veces con distintas partes de los datos, manteniendo siempre la proporción de churn (17/83) en cada vuelta. Así te asegurás de que el resultado no fue suerte. → Validación cruzada con StratifiedKFold con $k=5$,

Y mirá estas métricas, no la accuracy:

Recall: de los que se iban, ¿a cuántos detectaste? (Lo más importante para el negocio.)

Precision: de los que predijiste que se iban, ¿a cuántos acertaste?

PR-AUC: combinación que balancea los dos números anteriores.

Interpretación y comunicación

Un modelo sin interpretación es un modelo que no podés explicar. Y un modelo que no podés explicar, no sirve. Esto separa al que "hizo el TP" del que "resolvió un problema de negocio".

Interpretabilidad

- Feature importance: del modelo, pero ojo, no es causal
- SHAP values: globales (qué features pesan más) y locales (por qué predijo eso para ese cliente)

Reporte ejecutivo

Un gerente no va a leer el notebook. Creá un PDF de 4-6 páginas que un gerente comercial pueda leer en 10 minutos. Sin tecnicismos innecesarios.

- Pregunta de negocio + hallazgo clave
- Qué variables predicen churn (con gráfico SHAP simplificado)
- Performance del modelo en términos de negocio ("detecta a 7 de cada 10 clientes que se van a ir")
- Recomendación accionable: ¿qué palancas puede mover el equipo comercial? (campañas de retención a clientes con Tenure bajo, atención prioritaria a quienes hicieron Complain, etc.)
- Limitaciones y próximos pasos

7. Glosario

Para la defensa oral, vas a tener que explicar estos conceptos sin leer una definición. Si no podés, usá grill-me o Gentleman antes de la entrega.

Sobre el problema

Término	Qué significa	Cómo lo explicarías
Churn	Cliente que deja de comprarnos	"Como un alumno que se borra del gimnasio"
Class imbalance	Una clase aparece mucho más (83% vs 17%)	"Si decís que todos son diestros, acertás casi siempre pero no aprendiste nada"
Leakage	El modelo usa info que no tendría en la vida real	"Estudiar con las respuestas del examen: funciona en el lab, falla en producción"

Sobre el experimento

Término	Qué significa	Cómo lo explicarías
Train/test split	80% para entrenar, 20% para evaluar	"El examen sorprende que el modelo no puede ver hasta el final"
Stratified	El split mantiene la misma proporción de clases	"Que ambas porciones de la torta tengan el mismo % de chocolate"

Sobre los modelos

Término	Qué significa	Cómo lo explicarías
Baseline	El modelo más simple posible, tu piso	"Si el modelo complejo no le gana a tirar una moneda, algo salió mal"
Árbol de decisión	Preguntas sí/no hasta clasificar	"Un cuestionario: fácil de leer y explicarle a un gerente"
Random Forest	Cientos de árboles votando juntos	"En vez de un médico, le preguntás a 500 y votan"

Sobre las métricas

Término	Qué significa	Cómo lo explicarías
Accuracy	% total de aciertos — engañosa con desbalance	"Decir nunca churna nadie da 83%: suena bien, es inútil"
Recall	De los que se iban, ¿a cuántos detectaste?	"El radar del hospital: querés no perderte ningún caso"
Precision	De los que predijiste que se iban, ¿cuántos eran?	"¿Cuántos de los que mandaste a tratamiento realmente lo necesitaban?"
SHAP values	Cuánto aportó cada variable a cada predicción	"El ticket del super: no solo el total, sino qué producto sumó cuánto"

Skills:

📁 Los 5 Niveles de Skills para Claude